



# Modelos Univariados. Econometría Financiera Finanzas y Comercio Internacional

Andrés Martínez  
MSc Stochastic Engineering  
2019 - 2



# Contenido

- 1 Modelos Estacionarios**
  - Definiciones Básicas
  - Proceso General Lineal
  - Moving Average
  - Modelo Autoregresivo
  - Diagnóstico del Modelo
  
- 2 Modelos no Estacionarios**
  - Modelos ARIMA



# Contenidos del Corte

- Modelos Estacionarios [Jonathan and Kung-Sik, 2008]
  - Modelos de promedio movil *MA*
  - Modelos Autoregresivos *AR*
- Modelos no estacionarios y de Volatilidad
  - Modelos diferenciados *ARIMA*
  - Modelos ARCH
  - Modelos GARCH



# Modelos Estacionarios

## Definition

Un proceso estocástico es una familia de variables aleatorias  $Y_t$  para  $t \in I$ ,  $I \subseteq \mathbb{R}$ , definido en un espacio de probabilidad  $(\Omega, \mathcal{F}, P)$ . Una serie de tiempo es discreta  $I \subseteq \mathbb{Z}$ .

## Definition

Momentos de una serie de tiempo: Asumiendo que existen, la media  $\mu(t)$  y la función de covarianza  $\gamma(t, s)$  de  $Y_t$  para  $t \in \mathbb{Z}$

$$\mu(t) = E(Y_t)$$

$$\gamma(t, s) = E((Y_t - \mu_t)(Y_s - \mu_s))$$





# Modelos Estacionarios

## Definition

(Debil/Estrictamente) Estacionaria:

- 1  $Y_t$  con  $t \in \mathbb{Z}$  es debilmente estacionaria si  $E(Y_t^2) < \infty$ ,  $\mu(t) = \mu \in \mathbb{R}$  y  $\gamma(t+h, s+h)$  para todo  $t, s, h \in \mathbb{Z}$
- 2  $Y_t$  con  $t \in \mathbb{Z}$  es estrictamente estacionaria si  $(Y_{t_1}, \dots, Y_{t_n}) = (Y_{t_1+h}, \dots, Y_{t_n+h})$  para todo  $t_1, \dots, t_n$  con  $h \in \mathbb{Z}$  y  $n \in \mathbb{N}$



# Modelos Estacionarios

Un proceso lineal  $Y_t$ , se puede representar como una combinación ponderada de términos presentes y pasados de ruido blanco.

$$Y_t = \epsilon_t + \psi_1 \epsilon_{t-1} + \psi_2 \epsilon_{t-2} + \dots \quad (1)$$

$$\sum_{i=1}^{\infty} \psi_i^2 < \infty \quad (2)$$

Donde  $\psi$  cae de forma exponencial, resultando en

$$\psi_j = \phi^j$$

Donde  $\phi$  se encuentre entre 1 y  $-1$ .



# Modelos Estacionarios

$$Y_t = \epsilon_t + \phi\epsilon_{t-1} + \phi^2\epsilon_{t-2} + \dots \quad (4)$$

$$E[Y_t] = E(\epsilon_t + \phi\epsilon_{t-1} + \phi^2\epsilon_{t-2} + \dots) = 0 \quad (5)$$

$$\begin{aligned} V(Y_t) &= V(\epsilon_t + \phi\epsilon_{t-1} + \phi^2\epsilon_{t-2} + \dots) \\ &= V(\epsilon_t) + \phi^2 V(\epsilon_{t-1}) + \phi^4 V(\epsilon_{t-2}) + \dots \\ &= \sigma_\epsilon^2(1 + \phi^2 + \phi^4 + \dots) \\ &= \frac{\sigma_\epsilon^2}{1-\phi^2} \end{aligned}$$



# Modelos Estacionarios

$$\begin{aligned}
 \text{Cov}(Y_t, Y_{t-1}) &= \text{Cov}(\epsilon_t + \phi\epsilon_{t-1} + \phi^2\epsilon_{t-2} + \dots \\
 &\quad , \epsilon_{t-1} + \phi\epsilon_{t-2} + \phi^2\epsilon_{t-3} + \dots) \\
 &= \text{Cov}(\epsilon_{t-1}, \phi\epsilon_{t-1}) + \text{Cov}(\phi^2\epsilon_{t-2}, \epsilon_{t-2}) + \dots \\
 &= \phi\sigma_\epsilon^2 + \phi^3\sigma_\epsilon^2 + \phi^5\sigma_\epsilon^2 + \dots \\
 &= \phi\sigma_\epsilon^2(1 + \phi^2 + \phi^4 + \dots) \\
 &= \frac{\phi\sigma_\epsilon^2}{1-\phi^2}
 \end{aligned}$$





# Modelos Estacionarios


## Autocorrelación

$$\text{Corr}(Y_t, Y_{t-1}) = \left[ \frac{\phi \sigma_\epsilon^2}{1 - \phi^2} \right] / \left[ \frac{\sigma_\epsilon^2}{1 - \phi^2} \right] = \phi$$

$$\text{Corr}(Y_t, Y_{t-k}) = \left[ \frac{\phi^k \sigma_\epsilon^2}{1 - \phi^2} \right] / \left[ \frac{\sigma_\epsilon^2}{1 - \phi^2} \right] = \phi^k$$



Variable





# Modelos Estacionarios


## Moving Average MA(q)

$$Y_t = \epsilon_t - \Theta_1 \epsilon_{t-1} - \Theta_2 \epsilon_{t-2} - \dots - \Theta_q \epsilon_{t-q} \quad (6)$$

## Ecuación de Primer orden del MA(1)

$$Y_t = \epsilon_t - \Theta_1 \epsilon_{t-1} \text{ con } E[Y_t] = 0 \text{ y } V[Y_t] = \sigma_\epsilon^2(1 + \Theta^2)$$

$$\begin{aligned} \text{Cov}(Y_t, Y_{t-1}) &= \text{Cov}(\epsilon_t - \Theta \epsilon_{t-1}, \epsilon_{t-1} - \Theta \epsilon_{t-2}) \\ &= \text{Cov}(-\Theta \epsilon_{t-1}, \epsilon_{t-1}) \\ &= -\Theta \sigma_\epsilon^2 \end{aligned}$$



# Modelos Estacionarios

**Modelo MA(1)**  $Y_t = \epsilon_t - \Theta_1 \epsilon_{t-1}$

$$\begin{aligned}
 E(Y_t) &= 0 \\
 \gamma_0 &= V(Y_t) = \sigma_\epsilon^2(1 + \Theta^2) \\
 \gamma_1 &= -\Theta\sigma_\epsilon^2 \\
 \rho_1 &= -\Theta/(1 + \Theta^2)\gamma_0 = \rho_k = 0 \quad \text{para } k \geq 2
 \end{aligned}$$



# Modelos Estacionarios

**Ecuación de Segundo Orden MA(2)**  $Y_t = \epsilon_t - \Theta_1\epsilon_{t-1} - \Theta_2\epsilon_{t-2}$

$$\gamma_0 = V(Y_t) = V(\epsilon_t - \Theta_1\epsilon_{t-1} - \Theta_2\epsilon_{t-2}) = (1 + \Theta_1^2 + \Theta_2^2)\sigma_\epsilon^2$$


$$\gamma_1 = \text{Cov}(Y_t, Y_{t-1})$$

$$\gamma_1 = \text{Cov}(\epsilon_t - \Theta_1\epsilon_{t-1} - \Theta_2\epsilon_{t-2}, \epsilon_{t-1} - \Theta_1\epsilon_{t-2} - \Theta_2\epsilon_{t-3})$$

$$\gamma_1 = \text{Cov}(-\Theta_1\epsilon_{t-1}, \epsilon_{t-1}) + \text{Cov}(-\Theta_1\epsilon_{t-2}, -\Theta_2\epsilon_{t-2})$$

$$\gamma_1 = [-\Theta_1 + (-\Theta_1)(-\Theta_2)]\sigma_\epsilon^2$$

$$\gamma_1 = (-\Theta_1 + \Theta_1\Theta_2)\sigma_2^2$$



# Modelos Estacionarios



$$\begin{aligned}
 \gamma_2 &= \text{Cov}(Y_t, Y_{t-2}) \\
 \gamma_2 &= \text{Cov}(\epsilon_t - \Theta_1\epsilon_{t-1} - \Theta_2\epsilon_{t-2}, \\
 &\quad \epsilon_{t-2} - \Theta_1\epsilon_{t-3} - \Theta_2\epsilon_{t-4}) \\
 \gamma_2 &= \text{Cov}(-\Theta_2\epsilon_{t-2}, \epsilon_{t-2}) \\
 \gamma_2 &= -\Theta_2\sigma_\epsilon^2
 \end{aligned}$$


$$\rho_1 = \frac{-\Theta_1 + \Theta_1\Theta_2}{1 + \Theta_1^2 + \Theta_2^2}$$

$$\rho_2 = \frac{-\Theta_2}{1 + \Theta_1^2 + \Theta_2^2}$$



Figura: Rezagos





# Modelos Estacionarios

## Proceso General $MA(q)$

$$Y_t = \epsilon_t - \Theta_1 \epsilon_{t-1} - \Theta_2 \epsilon_{t-2} - \dots - \Theta_q \epsilon_{t-q} \quad (7)$$

$$\gamma_0 = (1 + \Theta_1^2 + \Theta_2^2 + \dots + \Theta_q^2) \sigma_\epsilon^2 \quad (8)$$

$$\rho_k = \frac{-\Theta_k + \Theta_1 \Theta_{k+1} + \Theta_2 \Theta_{k+2} + \dots + \Theta_q \Theta_{q-k}}{(1 + \Theta_1^2 + \Theta_2^2 + \dots + \Theta_q^2)} \quad (9)$$





# Modelos Estacionarios

**Ejemplo:** Use los principios para encontrar la función de autocorrelación para el proceso estacionario definido por

$$Y_t = 5 + \epsilon_t - \frac{1}{2}\epsilon_{t-1} + \frac{1}{4}\epsilon_{t-2}$$

**Solución**

$$\begin{aligned}
 V[Y_t] &= V(5 + \epsilon_t - \frac{1}{2}\epsilon_{t-1} + \frac{1}{4}\epsilon_{t-2}) \\
 &= [1 - (\frac{1}{2})^2 + (\frac{1}{4})^2]\sigma_\epsilon^2 \\
 &= \frac{28}{16}\sigma_\epsilon^2 \\
 Cov(Y_t, Y_{t-1}) &= Cov(\epsilon_t - \frac{1}{2}\epsilon_{t-1} + \frac{1}{4}\epsilon_{t-2}, \epsilon_{t-1} - \frac{1}{2}\epsilon_{t-2} + \frac{1}{4}\epsilon_{t-3}) \\
 Cov(Y_t, Y_{t-1}) &= Cov(-\frac{1}{2}\epsilon_{t-1} + \frac{1}{4}\epsilon_{t-2}, \epsilon_{t-1} - \frac{1}{2}\epsilon_{t-2}) \\
 Cov(Y_t, Y_{t-1}) &= Cov(-\frac{1}{2}\epsilon_{t-1}, \epsilon_{t-1}) + Cov(-\frac{1}{2}\epsilon_{t-2}, \frac{1}{4}\epsilon_{t-2}) \\
 Cov(Y_t, Y_{t-1}) &= [-\frac{1}{2}(\frac{1}{4}) - \frac{1}{2}]\sigma_\epsilon^2 \\
 &= -\frac{9}{8}\sigma_\epsilon^2
 \end{aligned}$$



# Modelos Estacionarios


## Solución

$$\text{Cov}(Y_t, Y_{t-2}) = \text{Cov}(\epsilon_t - \frac{1}{2}\epsilon_{t-1} + \frac{1}{4}\epsilon_{t-2}, \epsilon_{t-2} - \frac{1}{2}\epsilon_{t-3} + \frac{1}{4}\epsilon_{t-4})$$

$$\text{Cov}(Y_t, Y_{t-2}) = \text{Cov}(\frac{1}{4}\epsilon_{t-2}, \epsilon_{t-2}) = \frac{1}{4}\sigma_\epsilon^2$$

$$\text{Cov}(Y_t, Y_{t-3}) = \text{Cov}(-\frac{1}{2}\epsilon_{t-1}, \epsilon_{t-3}) + \text{Cov}(-\frac{1}{2}\epsilon_{t-4}, \frac{1}{4}\epsilon_{t-5}) = 0$$

$$\rho_k = \begin{cases} 1 & (k = 0) \\ -\frac{9}{8}\frac{\sigma_\epsilon^2}{28\sigma_\epsilon^2} & (k = 1) \\ -\frac{1}{4}\frac{\sigma_\epsilon^2}{28\sigma_\epsilon^2} & (k = 1) \\ 0 & k > 2 \end{cases}$$



# Modelos Estacionarios

**Modelo Autoregresivo** Un proceso autoregresivo  $Y_t$ , se puede representar como una combinación ponderada de términos presentes y pasados de la variable observada.

$$Y_t = Y_t + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \epsilon_t \quad (10)$$

## Ecuación de Primer orden del AR(1)

$$Y_t = Y_{t-1} \phi_{t-1} + \epsilon_t$$

Resolviendo la varianza

$$\gamma_0 = \phi^2 \gamma_0 + \sigma_\epsilon^2 \quad \rightarrow \quad \gamma_0 = \frac{\sigma_\epsilon^2}{1 - \phi^2} \quad (11)$$



# Modelos Estacionarios

El valor Esperado se obtiene multiplicando  $Y_{t-k}$  en ambos lados.  
Siendo el  $E(\epsilon_t) = 0$ .

$$Y_t = Y_{t-1}\phi_{t-1} + \epsilon_t \quad (12)$$

$$\begin{aligned} E(Y_{t-k}Y_t) &= \phi E(Y_{t-k}Y_{t-1}) + E(\epsilon_t Y_{t-k}) \\ \gamma_k &= \phi \gamma_{k-1} + E(\epsilon_t Y_{t-k}) \\ \gamma_k &= \phi \gamma_{k-1} \end{aligned}$$

Usando la varianza  $\gamma_0$  se puede despejar la covarianza para cualquier nivel.



# Modelos Estacionarios

$$\gamma_k = \phi^k \frac{\sigma_\epsilon^2}{1 - \phi^2} \quad (13)$$

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \phi^k \quad (14)$$

**Condición de estacionariedad** El modelo permanecerá estacionario y estable, en la medida en que  $|\phi| < 1$ .



# Modelos Estacionarios

## Ecuación de segundo orden del AR(2)

$$Y_t = Y_{t-1}\phi_{t-1} + Y_{t-2}\phi_{t-2} + \epsilon_t$$

Condiciones de estacionariedad:

Ecuación característica  $AR$  es un polinomio  $\phi(x) = 1 - \phi_1x - \phi_2x^2$

Ecuación característica  $1 - \phi_1x - \phi_2x^2 = 0$

Para cumplir con la condición, se requiere que las raíces excedan en 1 en valor absoluto.

$$\frac{\phi_1 \pm \sqrt{\phi_1^2 + 4\phi_2}}{-2\phi_2}$$



# Modelos Estacionarios

## Función Yule Walker y Función de Autocorrelación

Multiplicando  $Y_t = Y_{t-1}\phi_{t-1} + Y_{t-2}\phi_{t-2} + \epsilon_t$  por  $Y_{t-k}$  en ambos lados se puede obtener la función Yule Walker.

$$\gamma_k = \phi_1\gamma_{k-1} + \phi_2\gamma_{k-2} \quad (16)$$

Dividiendo por  $\gamma_0$

$$\rho_k = \phi_1\rho_{k-1} + \phi_2\rho_{k-2} \quad (17)$$



# Modelos Estacionarios

$$\rho_1 = \frac{\phi_1}{1 - \phi_2} \quad (18)$$

$$\rho_2 = \frac{\phi_2(1 - \phi_2) + \phi_1^2}{1 - \phi_2} \quad (19)$$

Finalmente la varianza de este proceso

$$\gamma_0 = \frac{(1 - \phi_2)\sigma_\epsilon^2}{(1 - \phi_2)(1 - \phi_1^2 - \phi_2^2) - 2\phi_2\phi_1^2} \quad (20)$$





# Modelos Estacionarios

## Modelo Autoregresivo Proceso General

$$Y_t = Y_t + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + \epsilon_t \quad (21)$$

## Ecuación de Primer orden del AR(p)

### AR polinomial

$$\phi(x) = 1 - \phi_1 x - \phi_2 x^2 - \dots - \phi_p x^p \quad (22)$$

### AR ecuación característica

$$0 = 1 - \phi_1 x - \phi_2 x^2 - \dots - \phi_p x^p \quad (23)$$



Implementando la ecuación Yule Walker se puede obtener la función de correlación para cualquier período.

$$\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2} + \dots + \phi_p \rho_{k-p} \quad (24)$$

La varianza se calcula usando la correlación en  $k$   $\rho_k = \gamma_k / \gamma_0$ .

$$\gamma_0 = \frac{\sigma_\epsilon^2}{1 - \phi_1 x - \phi_2 x^2 - \dots - \phi_p x^p} \quad (25)$$



# Modelos Estacionarios

**Ejemplo** Use la formula recursiva para calcula la función de autocorrelación para un proceso  $AR(2)$  con parámetros especificados. En cada caso especifique si las raices características son reales o complejas.

a  $\phi_1 = 0,6 \quad \phi_2 = 0,3$


b  $\phi_1 = -0,4 \quad \phi_2 = 0,5$

c  $\phi_1 = 1,2 \quad \phi_2 = -0,7$



## Solución Punto a


[1]  $1.081666-0i$   $-3.081666+0i$





## Solución punto b


[1]  $-1.069694+0i$     $1.869694-0i$





## Solución punto c

[1]  $0.8571429+0.8329931i$   $0.8571429-0.8329931i$





# Modelos no Estacionarios

**Modelos ARMA** Combinando los dos modelos se puede obtener una predicción de  $Y_t$  usando sus valores y los errores rezagados.

La forma general  $ARMA(p, q)$  de este proceso es:

$$Y_t = Y_{t-1}\phi_{t-1} + Y_{t-2}\phi_{t-2} + \dots + Y_{t-p}\phi_p + \epsilon_t - \Theta_1\epsilon_{t-1} - \Theta_2\epsilon_{t-2} - \dots - \Theta_q\epsilon_{t-q}$$



# Modelos Estacionarios

**Invertibilidad:** La función de autocorrelación para el proceso  $MA$  es la misma si  $\Theta = 1/\Theta$ , dado que este a través de un proceso de recursión se puede observar como  $Y_t = \Theta Y_{t-1} + \epsilon_t$  se puede decir que un proceso  $AR$  es  $MA$  pero infinito.

Por tal razón, si las raíces de los coeficientes de un modelo  $MA$  superan a 1, se puede decir que existe estacionariedad en el proceso  $MA$ .





**Función de Autocorrelación Parcial  $\phi_{kk}$**  Dado que la función de autocorrelación no se convierte en cero después de un número determinado de rezagos para un modelos  $AR(p)$  mientras que para un modelo  $MA(q)$  esto sucede después de  $q$ , se necesita una función de autocorrelación que permita ver en que momento termina el efecto de la variable rezadagada  $Y_{t-k}$  sobre  $Y_t$ .

Como en la función de autocorrelación se ve el efecto conjunto de cada uno de los rezagos sobre  $Y_t$ , es importante eliminar el efecto de los rezagos intermedios para poder ver el efecto directo de  $Y_{t-k}$  sobre  $Y_t$ .



**Cálculo de la Función:** Extrayendo la media de la serie de cada observación, se obtiene el primer orden de autoregresión. Para  $Y_t^* = Y_t - \mu$ .

$$Y_t^* = \phi_{11} Y_{t-1}^* + e_t \quad (26)$$

Para el período uno,

$$Y_t^* = \phi_{21} Y_{t-1}^* + \phi_{22} Y_{t-1}^* + e_t \quad (27)$$


Para el período 2. Luego generalizando la función:

$$\phi_{ss} = \frac{\rho_s - \sum_{j=1}^{s-1} \phi_{s-1,j} \rho_{s-j}}{1 - \sum_{j=1}^{s-1} \phi_{s-1,j} \rho_j} \quad (28)$$




Ejemplo: Obtenga un  $AR(1)$  con  $n = 36$  y  $\phi = 0,7$

- Calcule el ACF teórico
- Calcule el ACF simulado
- Calcule el PACF simulado




0 1 2 3 4 5 6 7 8 9  
1.000 0.700 0.490 0.343 0.240 0.168 0.118 0.082 0.058 0.040






### Series series





Series series





## Diagnóstico del Modelo

### Análisis de los residuales

Un modelo *ARIMA* que tiene una buena especificación, tiende a tener unos residuales que se aproximan a un ruido blanco con una distribución de observaciones independientes y que se comportan de forma normal.

Los residuales se pueden definir así:

$$\hat{\epsilon} = Y_t - \hat{\pi}_1 Y_{t-1} - \hat{\pi}_2 Y_{t-2} - \hat{\pi}_3 Y_{t-3} - \dots \quad (29)$$

Renombrandose como: *residual = actual – predicted*



El primer diagnóstico es inspeccionar los residuales en el tiempo. Si es el adecuado, se espera un comportamiento rectangular.

El segundo diagnóstico es encontrar la normalidad en los residuales, una forma facil de revisar este proceso, es a través del QQplot, haciendo la prueba de Jarque Bera o el test de Shapiro Wilk.

Por último en el análisis de residuales, se prueba la autocorrelación entre los residuales, buscando probar que no existe dado que ellos son independientes. La primera forma de saber esto es haciendo una grafica ACF, en tanto no exista autocorrelación, hay un indicio de que los residuales son independientes cumpliendo con el supuesto requerido.

El segundo método es usar el test de Portmanteau también conocido como el test de Ljung Box, en donde la hipótesis nula es








Call:


```
arima(x = color, order = c(1, 0, 0))
```

Coefficients:

	ar1	intercept
	0.5705	74.3293
s.e.	0.1435	1.9151


$\sigma^2$  estimated as 24.83: log likelihood = -106.07, aic

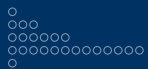







Normal Q-Q Plot






**Series residuals(m1.color)**







Standardized Residuals



ACF of Residuals



p values for Ljung-Box statistic



# Modelos no Estacionarios



# Modelos no Estacionarios


Un proceso  $ARIMA(p, 1, q)$  se define de la siguiente forma: con

$$W_t = Y_t - Y_{t-1}.$$

$$W_t = W_{t-1}\phi_{t-1} + W_{t-2}\phi_{t-2} + \dots + W_{t-p}\phi_p + \epsilon_t - \Theta_1\epsilon_{t-1} - \Theta_2\epsilon_{t-2} - \dots - \Theta_q\epsilon_{t-q}$$




## Precios Electricidad








## Transformación a Logaritmos



### Serie diferenciada



Jonathan, D. C. and Kung-Sik, C. (2008).  
Time series analysis with applications in r.



*SpringerLink, Springer eBooks.*